

A Comparative Study of Large Language Models and Traditional Privacy Measures to Evaluate Query Obfuscation Approaches

SIGIR ID. 1807

Anonymous Author(s)

A Prompt Definition

The prompts used to assess the privacy scores from the two LLMs are displayed in the green boxes.

Prompt Discrete - Likert Score

“Evaluate the information leakage from the original text to the obfuscated texts, providing a justification for each score given. Consider lexical and semantic similarities between original and obfuscated texts. *The score should be a integer between 1 and 5, where 1 indicates no information leakage and 5 indicates complete information leakage.* The original text is: **{original_text}**. The obfuscated texts are: **{obfuscated_texts}**. Respond only with the scores and justifications for each obfuscated text as instructed.”

Prompt Continuous - [0,1] Score

“Evaluate the information leakage from the original text to the obfuscated texts, providing a justification for each score given. Consider lexical and semantic similarities between original and obfuscated texts. *The score should be a float between 0 and 1, where 0 indicates no information leakage and 1 indicates complete information leakage.* The original text is: **{original_text}**. The obfuscated texts are: **{obfuscated_texts}**. Respond only with the scores and justifications for each obfuscated text as instructed.”

The different prompts employed adhere to the general template delineated in the primary manuscript, underscoring the necessity for the Large Language Model (LLM) to consider both lexical and semantic similarities between the original and obfuscated texts received.

B Experimental Evaluation

In this Section, we report the full table of the Mean Squared Error between Traditional Privacy evaluation Measures and the LLM privacy score. Table 1 reports the results.

Table 1: Mean Squared Errors between Traditional Evaluation measures, i.e., BLEU, Jaccard, and ROUGE, and the LLM score in the $[0,1]$ range across different ε -Privacy Budgets.

	LLM	Mechanism	DL'19										Med'04									
			1.0	5.0	10.0	12.5	15.0	17.5	20.0	25.0	30.0	50.0	1.0	5.0	10.0	12.5	15.0	17.5	20.0	25.0	30.0	50.0
BLEU Score	DeepSeek-R1	CMP	0.006	0.009	0.065	0.102	0.074	0.077	0.077	0.070	0.055	0.076	0.010	0.016	0.113	0.135	0.122	0.115	0.124	0.080	0.089	0.075
		Mahalanobis	0.008	0.009	0.057	0.074	0.090	0.074	0.088	0.059	0.060	0.072	0.007	0.014	0.070	0.098	0.138	0.122	0.130	0.124	0.102	0.105
		VickreyCMP	0.006	0.013	0.071	0.088	0.105	0.118	0.122	0.150	0.180	0.190	0.008	0.032	0.089	0.129	0.107	0.124	0.160	0.157	0.176	0.170
		VickreyMhl	0.007	0.010	0.037	0.059	0.085	0.110	0.114	0.118	0.134	0.186	0.008	0.010	0.061	0.08	0.103	0.122	0.125	0.156	0.157	0.183
	Llama 3.3	CMP	0.002	0.005	0.094	0.180	0.168	0.113	0.077	0.046	0.044	0.041	0.001	0.006	0.102	0.139	0.129	0.151	0.132	0.109	0.090	0.084
		Mahalanobis	0.003	0.002	0.061	0.13	0.164	0.161	0.139	0.082	0.050	0.045	0.001	0.009	0.067	0.097	0.121	0.124	0.171	0.155	0.093	0.087
		VickreyCMP	0.002	0.004	0.069	0.119	0.157	0.186	0.208	0.212	0.241	0.253	0.001	0.006	0.075	0.095	0.109	0.134	0.134	0.138	0.148	0.176
		VickreyMhl	0.001	0.005	0.030	0.067	0.105	0.143	0.174	0.207	0.219	0.255	0.001	0.004	0.040	0.085	0.110	0.116	0.124	0.123	0.134	0.172
Jaccard Score	DeepSeek-R1	CMP	0.006	0.009	0.036	0.052	0.056	0.064	0.060	0.065	0.062	0.084	0.010	0.015	0.062	0.039	0.050	0.061	0.071	0.070	0.073	0.049
		Mahalanobis	0.008	0.009	0.040	0.039	0.040	0.030	0.066	0.058	0.068	0.100	0.007	0.013	0.046	0.045	0.047	0.044	0.067	0.063	0.071	0.058
		VickreyCMP	0.006	0.012	0.056	0.058	0.066	0.074	0.071	0.094	0.118	0.121	0.008	0.030	0.066	0.086	0.060	0.080	0.106	0.102	0.114	0.103
		VickreyMhl	0.007	0.010	0.030	0.040	0.057	0.069	0.065	0.070	0.082	0.113	0.008	0.010	0.050	0.056	0.068	0.074	0.072	0.093	0.094	0.111
	Llama 3.3	CMP	0.002	0.005	0.057	0.082	0.06	0.042	0.032	0.032	0.038	0.035	0.001	0.006	0.048	0.044	0.046	0.108	0.079	0.061	0.043	0.041
		Mahalanobis	0.003	0.002	0.045	0.078	0.07	0.057	0.054	0.038	0.031	0.042	0.001	0.008	0.044	0.047	0.042	0.063	0.104	0.117	0.045	0.044
		VickreyCMP	0.002	0.004	0.054	0.082	0.101	0.119	0.133	0.14	0.159	0.161	0.001	0.006	0.052	0.056	0.061	0.083	0.084	0.085	0.092	0.105
		VickreyMhl	0.001	0.005	0.023	0.047	0.07	0.094	0.111	0.131	0.138	0.157	0.001	0.004	0.031	0.06	0.072	0.07	0.076	0.071	0.076	0.101
ROUGE Score	DeepSeek-R1	CMP	0.006	0.007	0.026	0.048	0.102	0.114	0.090	0.097	0.095	0.121	0.010	0.014	0.042	0.034	0.073	0.093	0.094	0.103	0.104	0.075
		Mahalanobis	0.007	0.009	0.030	0.030	0.044	0.055	0.113	0.095	0.097	0.145	0.007	0.013	0.033	0.028	0.043	0.069	0.105	0.084	0.103	0.089
		VickreyCMP	0.006	0.012	0.042	0.042	0.048	0.055	0.050	0.057	0.063	0.067	0.008	0.026	0.044	0.047	0.037	0.045	0.052	0.044	0.053	0.053
		VickreyMhl	0.007	0.009	0.024	0.030	0.041	0.043	0.043	0.049	0.050	0.064	0.008	0.010	0.039	0.038	0.039	0.044	0.039	0.048	0.052	0.065
	Llama 3.3	CMP	0.002	0.004	0.037	0.045	0.034	0.045	0.043	0.054	0.062	0.058	0.001	0.005	0.030	0.046	0.069	0.137	0.102	0.082	0.067	0.063
		Mahalanobis	0.003	0.002	0.036	0.055	0.043	0.037	0.05	0.052	0.050	0.065	0.001	0.008	0.031	0.035	0.049	0.091	0.129	0.148	0.070	0.066
		VickreyCMP	0.002	0.003	0.040	0.056	0.055	0.066	0.069	0.064	0.070	0.062	0.001	0.005	0.034	0.03	0.038	0.043	0.046	0.051	0.056	0.058
		VickreyMhl	0.001	0.005	0.018	0.034	0.048	0.058	0.064	0.068	0.066	0.072	0.001	0.004	0.023	0.039	0.045	0.040	0.052	0.049	0.052	0.063